Operações em Arquivos

Organização e Recuperação de Dados Profa. Valéria

UEM - CTC - DIN

Arquivos

- Um arquivo é uma estrutura criada em uma unidade de armazenamento secundário (HD, SSD, etc.)
 - Permite o armazenamento permanente dos dados, ao contrário das variáveis, que são armazenadas em RAM
- Do ponto de vista físico, um arquivo corresponde a uma sequência de bytes armazenados em um dispositivo secundário
 - Mas os aspectos físicos dos arquivos são transparentes para as aplicações

Diferentes visões do arquivo

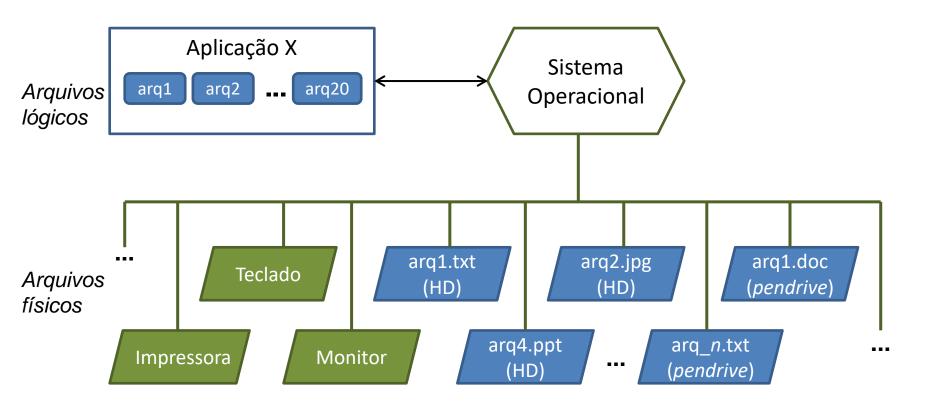
- Arquivo físico e arquivo lógico
 - Arquivo físico: é o arquivo do ponto de vista do armazenamento
 - Corresponde a uma sequência particular de bytes armazenados no dispositivo
 - Arquivo lógico: é o arquivo do ponto de vista da aplicação que o acessa
 - Cada arquivo manipulado pela aplicação é tratado como um canal de comunicação estabelecido entre a aplicação e o arquivo físico
- O sistema operacional é quem faz a interface entre o arquivo lógico e o arquivo físico

Diferentes visões do arquivo

- Apesar de um dispositivo secundário poder conter milhares de arquivos físicos, as aplicações, em geral, só podem abrir um número pré-definido de arquivos lógicos de forma simultânea
- Um arquivo lógico pode estar associado a um arquivo físico ou a outros dispositivos de E/S, como o teclado (stdin) e o vídeo (stdout e stderr)
- Quando uma aplicação solicita a abertura de um arquivo, o S.O. é informado sobre o modo como a associação entre o arquivo lógico e o físico deve ocorrer
 - A forma como essa informação é passada varia de acordo com o S.O.
 e a linguagem de programação utilizada

Conectando arquivo lógico ao físico

 A aplicação solicita que um nome lógico seja associado a um arquivo físico específico e o S.O. estabelece a associação

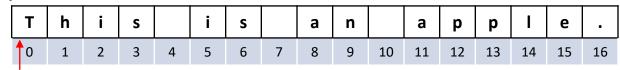


Arquivo lógico

- Do ponto de vista da aplicação, um arquivo é uma entidade lógica vista como uma sequência de bytes
 - A leitura e a escrita de informação no arquivo não se preocupa com os aspectos físicos do armazenamento
 - Podemos enviar bytes para o arquivo indefinidamente
 - De forma análoga, podemos ler bytes do arquivo enquanto houverem bytes a serem lidos
- Para todo arquivo lógico, é mantido um <u>ponteiro de L/E</u> que indica a posição do próximo byte a ser lido/escrito
 - Esse ponteiro se move automaticamente conforme operações de leitura e escrita são realizadas e também pode ser movido por comandos de reposicionamento

Arquivo lógico

 Quando um arquivo é aberto, o ponteiro de L/E é posicionado no início (byte 0)

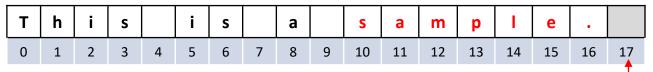


ponteiro de L/E

 Se for feita uma leitura de 9 bytes, o ponteiro de L/E se move automaticamente para a próxima posição de L/E (byte 9)

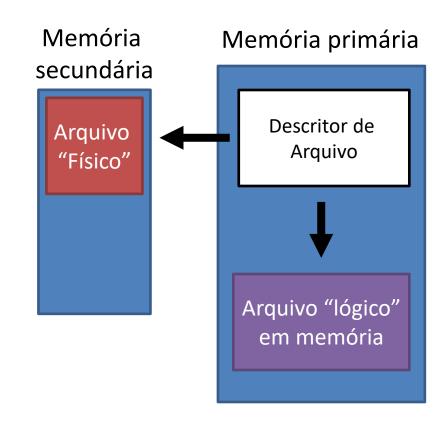


 Se for feita uma escrita de 8 bytes na sequência, o ponteiro de L/E se moverá para a próxima posição de L/E (byte 17)



Arquivo lógico

- O arquivo lógico é identificado pelo S.O. por um número inteiro chamado de descritor
- É comum que as linguagens encapsulem o <u>descritor do</u> <u>arquivo</u> em estruturas mais complexas, que armazenam outras informações úteis para a manipulação do arquivo
 - O tipo dessa estrutura descritora é dependente da linguagem
 - Em Python, essas informações ficam em um objeto de arquivo



Tipos de arquivos

Basicamente, são dois os tipos de arquivos

Texto

- Os <u>caracteres</u> são armazenados sequencialmente
- É possível determinar o primeiro, segundo, terceiro ... caracteres que compõem o arquivo
- Nesse tipo de arquivo, a sequência 123 corresponde à string "123"

- Binário

- Formado por uma sequência de <u>bytes</u> sem correspondência direta com um tipo de dado
- Cabe ao programador fazer essa correspondência quando lê e escreve nesses arquivos
- Nesse tipo de arquivo, o valor 123 será gravado como um número binário com uma quantidade pré-definida de bytes

Exemplo

 As figuras mostram um arquivo binário e um arquivo texto em um editor hexadecimal

No arquivo binario.dat, foi gravada a sequência de dígitos de 0 a 9 como valores inteiros de 4 bytes

No arquivo texto.txt foi gravada a sequência de dígitos de 0 a 9 como texto → '0', '1', ..., '9'

Operações em arquivos

- Basicamente, as operações em arquivos são as seguintes:
 - 1. Criar um arquivo
 - 2. Abrir um arquivo
 - 3. Ler de um arquivo
 - 4. Escrever em um arquivo
 - 5. Movimentar o ponteiro de L/E
 - 6. Fechar um arquivo
- Veremos como essas operações são feitas em Python

Operações em arquivos

- As funções da linguagem Python para manipular arquivos são implementadas de duas formas:
 - Como função nativa
 - Como métodos de objetos de arquivo
- A função open é nativa e utilizada para abrir/criar um arquivo, retornando um objeto de arquivo
 - A classe desse objeto varia de acordo com o tipo de arquivo a ser manipulado (leitura/escrita textual, leitura/escrita binária, etc.)
 - A partir do objeto de arquivo é possível acessar métodos para leitura, escrita, posicionamento, etc.

Métodos são funções declaradas no contexto de uma classe e são acessadas por meio de um objeto da classe

Operações em arquivos em Python

- A associação entre arquivo lógico e físico é feita no momento da abertura/criação do arquivo
 - O modo como a associação se dará depende do parâmetro utilizado para especificar o modo de abertura
 - O modo de abertura também especifica se um novo arquivo será criado ou se um arquivo existente será aberto

Criar e abrir arquivos

- def open (filename: str, mode: str) -> file object
 - filename é uma string contendo o nome do arquivo físico
 - mode também é uma string e define o modo de abertura
 - Caso a operação falhe, um erro ocorrerá e abortará a execução

Exemplo:

```
arq = open('meuarq.txt', 'w')
```

- modos de abertura → 'r' (read), 'w' (write), 'a' (append), 'x' (exclusive), 'r+', 'w+', 'a+', 'x+' 'rb', 'wb', 'ab', 'r+b', 'w+b', 'x+b', 'a+b'
- Por padrão, os arquivos são abertos em modo texto (flag 't')
 - A flag 'b' na string mode faz com que os arquivos sejam abertos em modo binário

flags da função open()

Caractere	Descrição do comportamento
'r'	Abre para leitura. O arquivo deve existir. É o modo padrão.
'w'	Abre para escrita. Se o arquivo existir, ele será trucando. Senão será criado.
'x'	Abre um novo arquivo para escrita. O arquivo não deve existir.
'a'	Abre para escrita no final do arquivo. Operações de reposicionamento do ponteiro de L/E são ignoradas. Se não existir, o arquivo será criado.
't'	Abre em modo texto. Admite apenas dados do tipo str. É o modo padrão.
ʻb'	Abre em modo binário. Admite apenas dados do tipo bytes/bytearray.
'+'	Altera o comportamento da <i>flag</i> inicial para permitir leitura e escrita.

Fique atento: as flags 't', 'b' e '+' só podem ser utilizadas em conjunto com outras

Mais informações: https://docs.python.org/3/library/functions.html#open

Criar e abrir arquivos

- Como tratar um erro na abertura do arquivo?
 - Em Python, erros de execução são chamados de exceções
 - As exceções podem ser capturadas e tratadas utilizando a instrução try-except

• Exemplo: try:

```
arq = open('meuArq.txt', 'r')
print('abertura ok')
except:
    print('Erro na abertura')
    exit()

Este trecho será
    executado apenas se
    ocorrer uma exceção
```

Fechamento de arquivos

- Uma vez que o arquivo foi aberto, o seu <u>fechamento</u> se dá pela chamada do método close()
 - Todos os objetos de arquivo possuem esse método
 - Encerra a associação entre o arquivo lógico e o físico
 - O descritor fica disponível para uso por outro arquivo
 - Garante que todas as informações do arquivo foram atualizadas (o fechamento garante que o conteúdo bufferizado foi enviado para o dispositivo físico)
 - O S.O. normalmente fecha qualquer arquivo que ficou aberto quando um programa termina corretamente, mas o ideal é fechar arquivos que não estão mais sendo utilizados
 - Previne a perde de dados bufferizados no caso de erro
 - Libera a estrutura descritora para novos arquivos

Fechamento de arquivos

Exemplo:

Sintaxe para a chamada de **métodos**: o nome do objeto seguido por ponto sempre precede o nome do método

 Quando o arquivo é aberto em um comando with, não é necessário o fechamento explícito

Atenção: neste caso, o objeto de arquivo arq só existirá no escopo do comando with

Leitura e escrita em arquivos

- Em Python, as funções de <u>leitura</u> e <u>escrita</u> são métodos do objeto de arquivo
 - Portanto, dependem do tipo do objeto
- Arquivos em modo texto são representados por objetos do tipo TextlOWrapper
 - Só admitem leitura e escrita de strings, i.e., objetos do tipo str
- Arquivos em modo binário são representados por objetos BufferedReader (leitura), BufferedWriter (escrita) e BufferedRandom (leitura e escrita)
 - Só admitem leitura e escrita de objetos do tipo bytes ou bytearray

bytes é um tipo <u>imutável</u> e <u>bytearray</u> é um tipo <u>mutável</u>. Ambos representam sequências de bytes.

Leitura em modo texto

def <u>read</u>(size=-1) -> str

- Lê e retorna no máximo size caracteres como uma única string
- Se size for negativo ou None, lê até o fim do arquivo (EOF), i.e., retorna todo o conteúdo do arquivo como uma única string

def <u>readline</u>(size=-1) -> str

- Lê até uma quebra de linha ou EOF e retorna o conteúdo como uma única string
- Se o ponteiro de L/E já estiver em EOF, retorna uma string vazia
- Se size for especificado, no máximo size caracteres serão lidos

def <u>readlines</u>(hint=-1) -> list[str]

- Retorna as linhas do arquivo como uma lista de strings
- Se hint for especificado, linhas serão lidas até o máximo de hint caracteres no total

Escrita em modo texto

- def <u>write(s) -> int</u>
 - Escreve a string s no arquivo
 - Retorna o número de caracteres escritos
- def <u>writelines</u>(lines) -> None
 - Escreve uma lista de strings no arquivo
 - Não são adicionados separadores entre as strings, então é comum que cada string contenha um caractere separador (p.e., '\n') no final

Leitura em modo binário

def <u>read</u>(size=-1) -> bytes

- Lê e retorna até size bytes
- Se o argumento for omitido, None ou negativo, o conteúdo do arquivo será lido até EOF e retornado.
- Um objeto bytes vazio (b") é retornado se o ponteiro de L/E estiver em EOF

def <u>readinto(b) -> int</u>

 Lê bytes para uma variável b, pré-alocada como um bytearray, e retorna o número de bytes lidos

def <u>readlines</u>(hint=-1) -> list[bytes]

- Retorna o conteúdo do arquivo como uma lista de linhas
- Considera o valor b'\n' como delimitador de linha
- Se hint for especificado, linhas serão lidas até o máximo de hint bytes no total

Escrita em modo binário

- def <u>write(b) -> int</u>
 - Escreve o objeto b do tipo bytes ou bytearray no arquivo
 - Retorna o número de bytes escritos (sempre será igual ao comprimento de b em bytes, pois uma falha na escrita irá gerar uma exceção)
- def <u>writelines</u>(lines) -> None
 - Escreve uma lista de linhas no arquivo
 - Não são adicionados separadores entre as linhas, então é comum que cada linha seja adicionada de um caractere separador (p.e., b'\n')

Mais informações: https://docs.python.org/3/library/io.html

Escreva um programa em Python que leia um dado arquivo texto caractere por caractere e os escreve na tela.

```
nomeArq = input('Digite o nome do arquivo: ')
arq = open(nomeArq, 'r')
c = arq.read(1)
while c:
    print(c)
    c = arq.read(1)
arq.close()
```

Escreva um programa em Python que leia um dado arquivo texto caractere por caractere e os escreve na tela.

```
nomeArq = input('Digite o nome do arquivo: ')
arq = open(nomeArq, 'r')
c = arq.read(1)
while c:
    print(c)
    c = arq.read(1)
arq.close()
Receba o nome do arquivo a ser
aberto e armazene-o em nomeArq
```

Escreva um programa em Python que leia um dado arquivo texto caractere por caractere e os escreve na tela.

```
nomeArq = input('Digite o nome do arquivo: ')
arq = open(nomeArq, 'r')
c = arq.read(1)
while c:
    print(c)
    c = arq.read(1)
arq.close()
Abra o arquivo nomeArq para leitura
em modo texto e chame-o de arq
arq.close()
```

Escreva um programa em Python que leia um dado arquivo texto caractere por caractere e os escreve na tela.

```
nomeArq = input('Digite o nome do arquivo: ')
arq = open(nomeArq, 'r')
c = arq.read(1)
while c:
    print(c)
    c = arq.read(1)
arq.close()
Leia um caractere de arq e armazeno-o em c.
Quando não houverem mais caracteres a serem
lidos, a função read retornará " (string vaizia)
```

Escreva um programa em Python que leia um dado arquivo texto caractere por caractere e os escreve na tela.

Escreva um programa em Python que leia um dado arquivo texto caractere por caractere e os escreve na tela.

Escreva um programa em Python que leia um dado arquivo texto caractere por caractere e os escreve na tela.

Escreva um programa em Python que leia um dado arquivo texto caractere por caractere e os escreve na tela.

```
nomeArq = input('Digite o nome do arquivo: ')
arq = open(nomeArq, 'r')
c = arq.read(1)
while c:
    print(c)
    c = arq.read(1)
arq.close()
    Feche arq
```

Versão alternativa 1:

```
nomeArq = input('Digite o nome do arquivo: ')
with open(nomeArq, 'r') as arq:
    c = arq.read(1)
    while c:
        print(c)
        c = arq.read(1)
```

Versão alternativa 2:

```
nomeArq = input('Digite o nome do arquivo: ')
try:
    with open(nomeArq, 'r') as arq:
        c = arq.read(1)
        while c:
        print(c)
        c = arq.read(1)
except:
    print(f'Não foi possível abrir o arquivo {nomeArq}.')
```

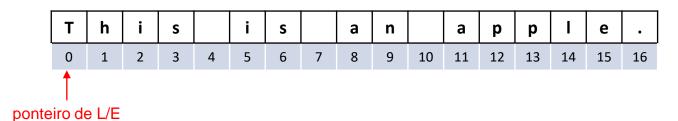
Detecção de fim de arquivo

- Durante a leitura de um arquivo, o S.O. monitora a posição do ponteiro de L/E do arquivo
- Em Python, não existe uma função específica para isso, mas as funções de leitura detectam o fim de arquivo
 - Nesse caso, as funções de leitura retornam um objeto vazio, seja uma string (") ou um byte (b")

```
nomeArq = input('Digite o nome do arquivo: ')
with open(nomeArq, 'r') as arq:
    c = arq.read(1)
    while c:
        print(c)
        c = arq.read(1)
Neste exemplo, note que como
controlamos a leitura até o fim do arquivo
testando o retorno da função read.
```

Posicionamento do ponteiro de L/E

- Funções de leitura e escrita movimentam o ponteiro de L/E do arquivo de forma automática
 - O ponteiro de L/E sempre avança quando lê/escreve
- Podemos movimentar o ponteiro de L/E para uma posição específica do arquivo utilizando método seek
 - Chamamos o tamanho do <u>deslocamento</u> a ser realizado de **byte**-offset
 - Quando esse deslocamento é contado a partir do início do arquivo, podemos pensar no offset como um "endereço" para onde se deseja mover o ponteiro de L/E



Posicionamento do ponteiro de L/E

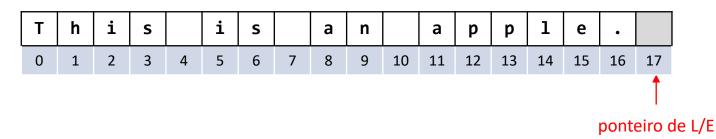
- def <u>seek</u> (offset, whence=os.SEEK_SET) -> int
 - Posiciona o ponteiro de L/E no byte offset calculado a partir da origem dada (whence)
 - Retorna o valor absoluto da nova posição
 - O parâmetro whence aceita os seguintes valores:
 - os.SEEK_SET ou 0 → início do arquivo. É o valor padrão
 - os.SEEK_CUR ou 1 → posição corrente do ponteiro de L/E
 - os.SEEK_END ou 2 → fim do arquivo
- Arquivos em <u>modo texto</u> só aceitam **seek** com *offsets* positivos a partir de os.SEEK_SET
 - Nesse caso, se whence for os.SEEK_CUR ou os.SEEK_END, o offset deverá ser 0

Exemplo seek

```
0
 ponteiro de L/E
antes da 1ª escrita
 import os
 file = open('example.txt', 'wb')
 s = 'This is an apple.'
 file.write(s.encode())
 file.seek(9, os.SEEK_SET)
 s = 'sam'
 file.write(s.encode())
 file.seek(3, os.SEEK_END)
 s = 'ok'
 file.write(s.encode())
 file.close()
```

O arquivo está sendo criado em **modo binário** para termos mais liberdade com o seek.

após a 1ª escrita



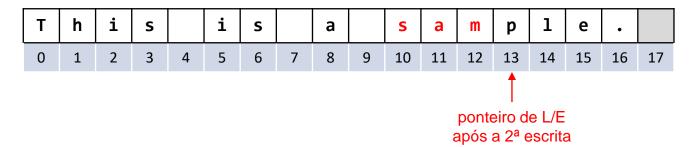
```
import os
file = open('example.txt', 'wb')
s = 'This is an apple.'
file.write(s.encode())
file.seek(9, os.SEEK_SET)
s = 'sam'
file.write(s.encode())
file.seek(3, os.SEEK_END)
s = 'ok'
file.write(s.encode())
file.close()
```



```
import os

file = open('example.txt', 'wb')
s = 'This is an apple.'
file.write(s.encode())
file.seek(9, os.SEEK_SET)
s = 'sam'
file.write(s.encode())
file.seek(3, os.SEEK_END)
s = 'ok'
file.write(s.encode())
file.close()
```

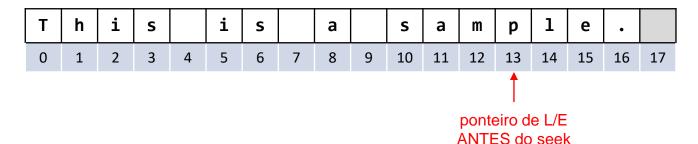
```
Byte-offset = 9
Origem = 0 (SEEK_SET)
Nova posição do ponteiro de L/E:
0 + 9 = 9
```

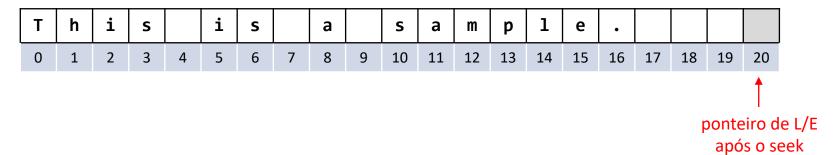


```
import os

file = open('example.txt', 'wb')
s = 'This is an apple.'
file.write(s.encode())
file.seek(9, os.SEEK_SET)
s = 'sam'
file.write(s.encode())
file.seek(3, os.SEEK_END)
s = 'ok'
file.write(s.encode())
file.close()
```

Escrita a partir da nova posição, avançando o ponteiro de L/E





```
import os

file = open('example.txt', 'wb')
s = 'This is an apple.'
file.write(s.encode())
file.seek(9, os.SEEK_SET)
s = 'sam'
file.write(s.encode())
file.seek(3, os.SEEK_END)
s = 'ok'
file.write(s.encode())
file.close()
```

```
offset = 3
whence = 17 (SEEK_END)
Nova posição do ponteiro de L/E:
17 + 3 = 20
```

O ponteiro avançará 3 bytes à frente do fim (offset 17), mesmo não havendo nada lá.

Pararia no offset 20.

Offsets positivos SEMPRE avançam em direção ao fim do arquivo.



ponteiro de L/E após a 3ª escrita

```
import os

file = open('example.txt', 'wb')
s = 'This is an apple.'
file.write(s.encode())
file.seek(9, os.SEEK_SET)
s = 'sam'
file.write(s.encode())
file.seek(3, os.SEEK_END)
s = 'ok'
file.write(s.encode())
```

file.close()

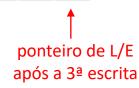
As posições vazias são preenchidas com zeros

Posicionamento do ponteiro de L/E

- Como voltar o ponteiro de L/E para o início?
 - arq.seek(0)
- Como posicionar o ponteiro de L/E no fim?
 - arq.seek(0, os.SEEK_END)
- Como saber em qual posição o ponteiro de L/E está?
 - Todo objeto de arquivo possui um método tell
 - def <u>tell</u> () -> int
 - Retorna a posição atual do ponteiro de L/E como um número inteiro

Т	h	i	S		i	s		а		S	а	m	р	1	e	•	\0	\0	\0	0	k	
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22

```
>>>file.tell()
22
```



Arquivos e o S.O.

- Marcação de fim de linha
 - Dependendo do S.O. utilizado, a representação de fim de linha muda
 - DOS/Windows utiliza dois bytes
 - Par CR-LF (decimal ASCII 13 e 10 \rightarrow hex 0D 0A)
 - Unix/Linux utiliza um byte
 - LF (decimal ASCII 10 \rightarrow hex 0A)
 - Para vermos essa marcação precisamos usar um editor hexadecimal
 - https://hexed.it/
 - https://www.onlinehexeditor.com/

Arquivos e o S.O.

Visualização do arquivo em um editor de texto

arquivo.txt

primeira linha segunda linha terceira e ultima linha



Visualização do arquivo em um editor hexadecimal

Offset: 00 01 02 03 04 05 06 07 08 09 0A 0B 0C 0D 0E 0F 000000000: 70 72 69 6D 65 69 72 61 20 6C 69 6E 68 61 0D 0A 00000010: 73 65 67 75 6E 64 61 20 6C 69 6E 68 61 0D 0A 74 00000020: 65 72 63 65 69 72 61 20 65 20 75 6C 74 69 6D 61 00000030: 20 6C 69 6E 68 61

Tabela ASCII



'\n'

primeira.linha..
segunda.linha..t
erceira.e.ultima
.linha

Arquivos e o S.O.

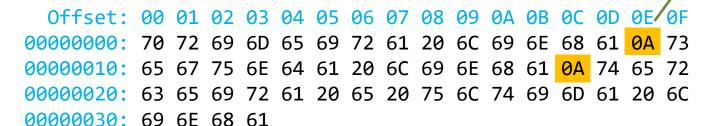
Visualização do arquivo em um editor de texto

arquivo.txt

primeira linha segunda linha terceira e ultima linha

Linux

Visualização do arquivo em um editor hexadecimal



primeira.linha.s
egunda.linha.ter
ceira.e.ultima.l
inha

Arquivos binários em Python

- Os arquivos binários em Python realizam escrita e leitura apenas com os tipos bytes e bytearray
- Alguns tipos fornecem métodos de conversão prontos para os tipos binários
 - Conversão de inteiros:
 - <int>.to_bytes(n) → converte inteiro para n bytes
 - int.from_bytes(<bytes>) → converte bytes para inteiro
 - Conversão de strings:
 - <str>.encode() → converte string para bytes
 - <bytes>.decode() → converte bytes para string

arquivo.txt

Olha que coisa mais linda, mais cheia de graca.

```
arq = open('arquivo.txt', 'r')
```

```
Offset: 00 01 02 03 04 05 06 07 08 09 0A 0B 0C 0D 0E 0F TEXTO DECODIFICADO 00000000: 4F 6C 68 61 20 71 75 65 20 63 6F 69 73 61 20 6D Olha.que.coisa.m 00000010: 61 69 73 20 6C 69 6E 64 61 2C 0A 6D 61 69 73 20 cheia.de.graca.
```

```
s = arq.readline()
print(s)
```

Olha que coisa mais linda,

arquivo.txt

Olha que coisa mais linda, mais cheia de graca.

```
Leitura binária!

arq = open('arquivo.txt', 'rb')
```

```
Offset: 00 01 02 03 04 05 06 07 08 09 0A 0B 0C 0D 0E 0F TEXTO DECODIFICADO 00000000: 4F 6C 68 61 20 71 75 65 20 63 6F 69 73 61 20 6D Olha.que.coisa.m 00000010: 61 69 73 20 6C 69 6E 64 61 2C 0A 6D 61 69 73 20 ais.linda, mais. 00000020: 63 68 65 69 61 20 64 65 20 67 72 61 63 61 2E cheia.de.graca.
```

```
s = arq.readline()
print(s)
```

b'Olha que coisa mais linda,\n'

arquivo.txt

Olha que coisa mais linda, mais cheia de graca.

```
Leitura binária!

arq = open('arquivo.txt', 'rb')
```

```
Offset: 00 01 02 03 04 05 06 07 08 09 0A 0B 0C 0D 0E 0F TEXTO DECODIFICADO 00000000: 4F 6C 68 61 20 71 75 65 20 63 6F 69 73 61 20 6D Olha.que.coisa.m 00000010: 61 69 73 20 6C 69 6E 64 61 2C 0A 6D 61 69 73 20 ais.linda, mais. 00000020: 63 68 65 69 61 20 64 65 20 67 72 61 63 61 2E cheia.de.graca.
```

```
s = arq.readline()
print(s.decode())
```

Olha que coisa mais linda

arquivo.txt

Olha que coisa mais linda, mais cheia de graca.

```
Leitura binária!

arq = open('arquivo.txt', 'rb')
```

```
Offset: 00 01 02 03 04 05 06 07 08 09 0A 0B 0C 0D 0E 0F TEXTO DECODIFICADO 00000000: 4F 6C 68 61 20 71 75 65 20 63 6F 69 73 61 20 6D Olha.que.coisa.m 00000010: 61 69 73 20 6C 69 6E 64 61 2C 0A 6D 61 69 73 20 ais.linda, mais. 00000020: 63 68 65 69 61 20 64 65 20 67 72 61 63 61 2E cheia.de.graca.
```

```
v1: 0x4F = 79
```

```
v1 = int.from_bytes(arq.read(1))
v2 = int.from_bytes(arq.read(1))
print(v1 + v2)
```