Organização e Recuperação de Dados Profa. Valéria

UEM - CTC - DIN

Slides preparados com base no Cap. 7 do livro FOLK, M.J. & ZOELLICK, B. *File Structures*. 2nd Edition, Addison-Wesley Publishing Company, 1992, e nos slides disponibilizados pelo Prof. Pedro de Azevedo Berger (DCC/UnB)

Objetivo

- Processar de forma <u>coordenada</u> duas ou mais listas sequenciais para produzir uma lista única como saída
 - Por ex., duas ou mais listas de chaves de primárias

As listas de entrada:

- Devem estar ordenadas por chave
- Não devem possuir chaves duplicadas

A lista de saída:

- Será <u>ordenada por chave</u>
- Não possuirá chaves duplicadas

- Tipos de listas resultantes:
 - Interseção (Match)
 - A lista de saída é formada por chaves que ocorrem em todas as listas de entrada
 - União/Intercalação (Merge)
 - A lista de saída é formada por todas as chaves das listas de entrada, sem duplicação
 - Os itens são intercalados pela ordem de chave

- Os algoritmos devem contemplar:
 - Inicialização
 - Abertura dos arquivos de entrada e saída
 - Inicialização da variável de controle do laço
 - Inicialização de variáveis usadas na checagem de sequência
 - Leitura dos arquivos
 - Teste da condição de parada
 - Reconhecimento de erro para os arquivos de entrada
 - Verificar se existem chaves duplicadas
 - Verificar se a sequência de chaves está desordenada
 - Sincronização das leituras e geração da saída

Interseção (Matching)

Lista1

Adams

Carter

Chin

Davis

Foster

Garwich

Johnson

Rosewald

Turner

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

Dempsey

Rosewald

Schmidt

Thayer

Walsh

Willis

Interseção

Interseção (Matching)



Interseção (Matching)

Lista1

Adams

Carter

Chin

Davis

Foster

Garwich

Johnson

Rosewald

Turner

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

Dempsey

Rosewald

Schmidt

Thayer

Walsh

Willis

Interseção

Adams

Interseção (Matching)

Lista1 Lista2 Adams Adams Carter --Andrews Chin Bech Davis Burns Foster Carter Garwich Davis Johnson Dempsey Rosewald Rosewald Turner Schmidt Thayer

Walsh

Willis

Interseção

Adams

Interseção (Matching)

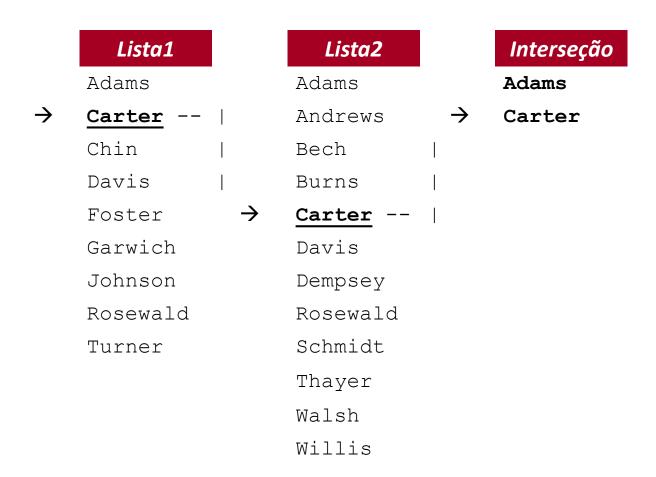
Lista1 Lista2 Adams Adams Carter --Andrews Chin Bech Davis \rightarrow Burns Foster Carter Garwich Davis Johnson Dempsey Rosewald Rosewald Turner Schmidt Thayer Walsh

Willis

Interseção

Adams

Interseção (Matching)



Interseção (Matching)

Lista1

Adams

Carter

 \rightarrow Chin ----

Davis

Foster

Garwich

Johnson

Rosewald

Turner

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

 \rightarrow

Dempsey

Rosewald

Schmidt

Thayer

Walsh

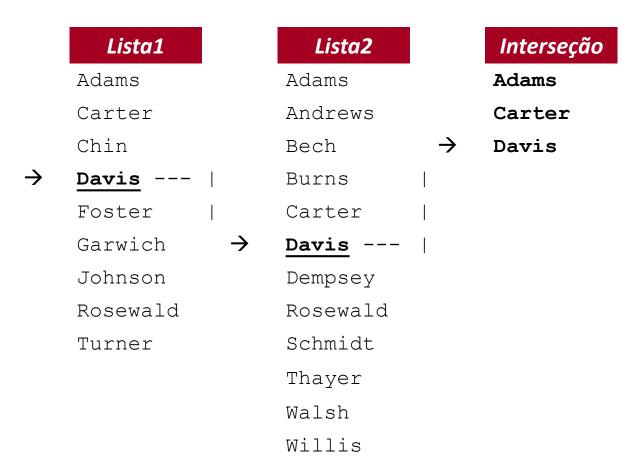
Willis

Interseção

Adams

Carter

Interseção (Matching)



Interseção (Matching)

Lista1

Adams

Carter

Chin

Davis

 \rightarrow Foster -- |

Garwich

Johnson

Rosewald

Turner

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

 \rightarrow

Dempsey

Rosewald

Schmidt

Thayer

Walsh

Willis

Interseção

Adams

Carter

Interseção (Matching)

Lista1

Adams

Carter

Chin

Davis

→ Foster --

Garwich

Johnson

Rosewald

Turner

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

 \rightarrow

Dempsey

Rosewald

Schmidt

Thayer

Walsh

Willis

Interseção

Adams

Carter

Interseção (Matching)

Lista1

Adams

Carter

Chin

Davis

Foster

 \rightarrow Garwich -

Johnson

Rosewald

Turner

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

 \rightarrow

Dempsey

Rosewald

Schmidt

Thayer

Walsh

Willis

Interseção

Adams

Carter

Interseção (Matching)

Lista1

Adams

Carter

Chin

Davis

Foster

Garwich

→ Johnson - |

Rosewald

Turner

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

 \rightarrow

Dempsey

Rosewald

Schmidt

Thayer

Walsh

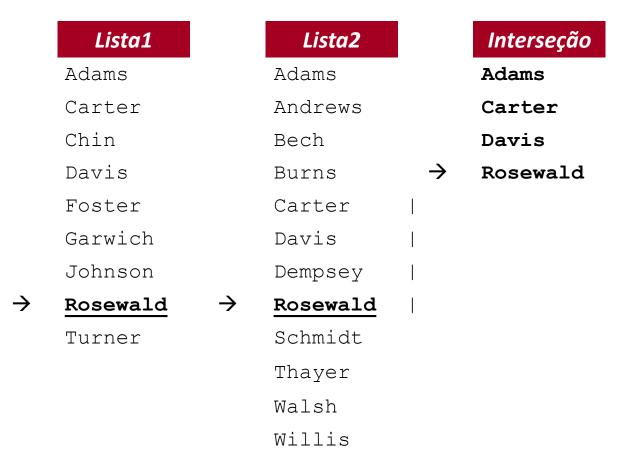
Willis

Interseção

Adams

Carter

Interseção (Matching)



Interseção (Matching)

Lista1

Adams

Carter

Chin

Davis

Foster

Garwich

Johnson

Rosewald

→ Turner

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

Dempsey

Rosewald

→ Schmidt

Thayer

Walsh

Willis

Interseção

Adams

Carter

Davis

Interseção (Matching)

Lista1

Adams

Carter

Chin

Davis

Foster

Garwich

Johnson

Rosewald

→ <u>Turner</u> --

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

Dempsey

Rosewald

Schmidt

→ Thayer

Walsh

Willis

Interseção

Adams

Carter

Davis

Interseção (Matching)

Lista1

Adams

Carter

Chin

Davis

Foster

Garwich

Johnson

Rosewald

 \rightarrow <u>Turner</u> --

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

Dempsey

Rosewald

Schmidt

Thayer

 \rightarrow Walsh

Willis

Interseção

Adams

Carter

Davis

Interseção (Matching)

Lista1

Adams

Carter

Chin

Davis

Foster

Garwich

Johnson

Rosewald

Turner

EOF

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

Dempsey

Rosewald

Schmidt

Thayer

Willis

→ <u>Walsh</u>

Interseção

Adams

Carter

Davis

- Sincronização dos arquivos
 - Se Nome1 < Nome2, lemos o próximo da Lista1
 - Se Nome1 > Nome2, lemos o próximo da Lista2
 - Se Nome1 = Nome2, escrevemos o nome na saída e lemos os próximos nomes das listas 1 e 2

FUNÇÃO inicialize()

```
# VALOR_BAIXO é um valor constante que sempre será
# menor que qualquer valor das listas de entrada

ANTERIOR1 := VALOR_BAIXO

ANTERIOR2 := VALOR_BAIXO

abra o arquivo com a lista 1 para leitura como LISTA1

abra o arquivo com a lista 2 para leitura como LISTA2

abra o arquivo de saída para escrita como SAIDA

EXISTEM_MAIS_NOMES := TRUE

retorne ANTERIOR1, ANTERIOR2, LISTA1, LISTA2, SAIDA, EXISTEM_MAIS_NOMES

fim FUNÇÃO
```

```
FUNÇÃO match()
   chame inicialize()
   chame leia_nome() para ler NOME1 da LISTA1
   chame leia nome() para ler NOME2 da LISTA2
   enquanto EXISTEM MAIS NOMES faça
        se NOMF1 < NOMF2 então
                 chame leia nome() para ler NOME1 da LISTA1
        senão se NOME1 > NOME2 então
                 chame leia_nome() para ler NOME2 da LISTA2
                /* chaves iquais */
        senão
                 escreva NOME1 em SAIDA
                 chame leia_nome() para ler NOME1 da LISTA1
                 chame leia nome() para ler NOME2 da LISTA2
   feche LISTA1, LISTA2 e SAIDA
fim FUNÇÃO
```

→ Intercalação (Merge)



➡ Intercalação (Merge)

Lista1
Adams
Carter
→
Chin

Davis Foster

Garwich

Johnson

Rosewald

Turner

Lista2

Adams

<u>Andrews</u>

Bech

Burns

Carter

Davis

Dempsey

Rosewald

Schmidt

Thayer

Walsh

Willis

Saída

Adams

Andrews

→ Intercalação (Merge)

Lista1 Lista2 Saída Adams Adams Adams Carter --Andrews Andrews Chin \rightarrow Bech Bech Davis Burns Foster Carter Garwich Davis Johnson Dempsey Rosewald Rosewald Turner Schmidt Thayer Walsh Willis

→ Intercalação (Merge)

Lista1 Lista2 Saída Adams Adams Adams Carter --Andrews Andrews Chin Bech Bech Davis \rightarrow Burns Burns Foster Carter Garwich Davis Johnson Dempsey Rosewald Rosewald Turner Schmidt Thayer Walsh Willis

➡ Intercalação (Merge)

Lista1 Lista2 Saída Adams Adams Adams Carter --Andrews Andrews Chin Bech Bech Davis Burns Burns \rightarrow \rightarrow Foster Carter Carter Garwich Davis Johnson Dempsey Rosewald Rosewald Turner Schmidt Thayer Walsh Willis

→ Intercalação (Merge)

Lista1 Lista2 Saída Adams Adams Adams Carter Andrews Andrews \rightarrow Bech Bech Chin ---Davis Burns Burns Foster Carter Carter Garwich \rightarrow Chin Davis Johnson Dempsey Rosewald Rosewald Turner Schmidt Thayer Walsh Willis

→ Intercalação (Merge)

Lista1 Lista2 Saída Adams Adams Adams Carter Andrews Andrews Chin Bech Bech \rightarrow Davis ---Burns Burns Foster Carter Carter Garwich \rightarrow Davis ---Chin Johnson Dempsey Davis Rosewald Rosewald Turner Schmidt Thayer Walsh Willis

→ Intercalação (Merge)

Lista1 Lista2 Saída Adams Adams Adams Carter Andrews Andrews Chin Bech Bech Davis Burns Burns \rightarrow Foster --Carter Carter Garwich Chin Davis Dempsey -Johnson \rightarrow Davis Rosewald Rosewald Dempsey Turner Schmidt Thayer Walsh Willis

→ Intercalação (Merge)

Lista1 Lista2 Saída Adams Adams Adams Carter Andrews Andrews Chin Bech Bech Davis Burns Burns \rightarrow Foster --Carter Carter Garwich Chin Davis Johnson Dempsey Davis Rosewald \rightarrow Rosewald Dempsey Turner Schmidt \rightarrow Foster Thayer Walsh Willis

➡ Intercalação (Merge)

Lista1 Lista2 Saída Adams Adams Adams Carter Andrews Andrews Chin Bech Bech Davis Burns Burns Foster Carter Carter \rightarrow Chin Garwich -Davis Johnson Dempsey Davis Rosewald \rightarrow Rosewald Dempsey Turner Schmidt Foster Thayer \rightarrow Garwich Walsh Willis

→ Intercalação (Merge)

	Lista1	Lista2		Saída
	Adams	Adams		Adams
	Carter	Andrews		Andrews
	Chin	Bech		Bech
	Davis	Burns		Burns
	Foster	Carter		Carter
	Garwich	Davis		Chin
>	Johnson -	Dempsey		Davis
	Rosewald \rightarrow	Rosewald		Dempsey
	Turner	Schmidt		Foster
		Thayer		Garwich
		Walsh	\rightarrow	Johnson
		Willis		

				_		
	Lista1		Lista2			Saída
	Adams		Adams	_		Adams
	Carter		Andrews			Andrews
	Chin		Bech			Bech
	Davis		Burns			Burns
	Foster		Carter			Carter
	Garwich		Davis			Chin
	Johnson		Dempsey			Davis
\rightarrow	Rosewald	\rightarrow	Rosewald			Dempsey
	Turner		Schmidt			Foster
			Thayer			Garwich
			Walsh	I		Johnson
			Willis		\rightarrow	Rosewald

	Lista1		Lista2		Saída
	Adams		Adams	-	Adams
	Carter		Andrews		Andrews
	Chin		Bech		Bech
	Davis		Burns		Burns
	Foster		Carter		Carter
	Garwich		Davis		Chin
	Johnson		Dempsey		Davis
	Rosewald		Rosewald		Dempsey
>	<u>Turner</u>	\rightarrow	Schmidt -	1	Foster
			Thayer		Garwich
			Walsh		Johnson
			Willis	\rightarrow	

	Lista1		Lista2		Saída
	Adams		Adams		Adams
	Carter		Andrews		Andrews
	Chin		Bech		Bech
	Davis		Burns		Burns
	Foster		Carter		Carter
	Garwich		Davis		Chin
	Johnson		Dempsey		Davis
	Rosewald		Rosewald		Dempsey
>	<u>Turner</u>		Schmidt		Foster
		\rightarrow	Thayer -	-	Garwich
			Walsh		Johnson
			Willis	\rightarrow	

	Lista1		Lista2		Saída
	Adams		Adams		Adams
	Carter		Andrews		Andrews
	Chin		Bech		Bech
	Davis		Burns		Burns
	Foster		Carter		Carter
	Garwich		Davis		Chin
	Johnson		Dempsey		Davis
	Rosewald		Rosewald		Dempsey
\rightarrow	<u>Turner</u>		Schmidt		Foster
		1	Thayer		Garwich
		\rightarrow	Walsh		Johnson
			Willis	\rightarrow	• • •

Lista1		Lista2		Saída
Adams		Adams		Adams
Carter		Andrews		Andrews
Chin		Bech		Bech
Davis		Burns		Burns
Foster		Carter		Carter
Garwich		Davis		Chin
Johnson		Dempsey		Davis
Rosewald		Rosewald		Dempsey
Turner		Schmidt		Foster
EOF		Thayer		Garwich
	\rightarrow	Walsh		Johnson
		Willis	\rightarrow	• • •

➡ Intercalação (Merge)

Lista1 Lista2 Saída Adams Adams Adams Carter Andrews **Andrews** Chin Bech Bech Davis Burns Burns Foster Carter Carter Garwich Chin Davis Johnson Dempsey Davis Rosewald Rosewald Dempsey Turner Schmidt Foster **EOF** Thayer Garwich Walsh Johnson \rightarrow Willis --Willis

➡ Intercalação (Merge)

Lista1

Adams

Carter

Chin

Davis

Foster

Garwich

Johnson

Rosewald

Turner

EOF

Lista2

Adams

Andrews

Bech

Burns

Carter

Davis

Dempsey

Rosewald

Schmidt

Thayer

Walsh

Willis

EOF

Saída

Adams

Andrews

Bech

Burns

Carter

Chin

Davis

Dempsey

Foster

Garwich

Johnson

. . .

Willis

Intercalação (Merge)

Sincronização dos arquivos

- Se Nome1 < Nome2, escrevemos o nome1 na saída lemos o próximo da Lista1
- Se Nome1 > Nome2, escrevemos o nome2 na saída lemos o próximo da Lista2
- Se Nome1 = Nome2, escrevemos o nome1 na saída e lemos os próximos nomes das listas 1 e 2

Intercalação

FUNÇÃO inicialize()

```
# VALOR_BAIXO é um valor constante que sempre será
# menor que qualquer valor das listas de entrada

ANTERIOR1 := VALOR_BAIXO

ANTERIOR2 := VALOR_BAIXO

abra o arquivo com a lista 1 para leitura como LISTA1

abra o arquivo com a lista 2 para leitura como LISTA2

abra o arquivo de saída para escrita como SAIDA

EXISTEM_MAIS_NOMES := TRUE

retorne ANTERIOR1, ANTERIOR2, LISTA1, LISTA2, SAIDA, EXISTEM_MAIS_NOMES

fim FUNÇÃO
```

Intercalação

```
FUNÇÃO leia_nome(LISTA, NOME_ANT, NOME_OUTRA_LISTA, EXISTEM_MAIS_NOMES)
    leia NOME do arquivo LISTA
    se EOF então
       # VALOR ALTO é um valor constante que sempre será maior que qualquer outro
       se NOME OUTRA LISTA = VALOR ALTO então
           EXISTEM_MAIS_NOMES := FALSE # fim das duas listas
       senão NOME := VALOR_ALTO
                                    # fim da lista atual
    senão # existem mais nomes
       se NOME <= NOME ANT então
           gere um erro: 'Erro na checagem de sequência'
    NOME ANT := NOME
    retorne NOME, NOME ANT, EXISTEM MAIS NOMES
fim FUNÇÃO
```

Intercalação

```
FUNÇÃO merge()
     chame inicialize()
     chame leia nome() para ler NOME1 da LISTA1
     chame leia nome() para ler NOME2 da LISTA2
     enquanto EXISTEM MAIS NOMES faça
        se NOME1 < NOME2 então # chave da LISTA1 é menor
          escreva NOME1 em SAIDA
          chame leia nome() para ler NOME1 da LISTA1
        senão se NOME1 > NOME2 então # chave da LISTA2 é menor
          escreva NOME2 em SAIDA
          chame leia_nome() para ler NOME2 da LISTA2
        senão
                   # as chaves são iguais
          escreva NOME1 em SAIDA
          chame leia_nome() para ler NOME1 da LISTA1
          chame leia_nome() para ler NOME2 da LISTA2
    feche LISTA1, LISTA2 e SAIDA
fim FUNÇÃO
```

Intercalação múltipla (K-way Merge)

- Algoritmo K-way merge: intercala K arquivos ordenados, gerando um único arquivo ordenado de saída
 - O valor K é a ordem do merge
 - A parte mais cara do processo são os testes para verificar em quais arquivos a menor chave ocorreu, para se saber quais arquivos devem ser lidos a seguir

```
enquanto EXISTEM_MAIS_NOMES faça

NOME_SAIDA := menor(NOME1, NOME2, NOME3, ..., NOMEK)
escreva NOME_SAIDA em SAIDA

se NOME1 = NOME_SAIDA então
    chame leia_nome() para ler NOME1 da LISTA1

se NOME2 = NOME_SAIDA então
    chame leia_nome() para ler NOME2 da LISTA2
    ...

se NOMEK = NOME_SAIDA então
    chame leia_nome() para ler NOMEK da LISTAK

fim enquanto
```

K-Way Merge

- Condição de parada
 - Pode-se usar uma variável contadora
 - Inicia com 0 e é incrementada cada vez que um dos arquivos chega ao fim
 - A condição de parada se torna verdadeira se ocorrer EOF e o contador atingir o número de arquivos de entrada

```
FUNÇÃO leia_nome()
...
se EOF então
NOME := VALOR_ALTO
numEOF := numEOF + 1
se numEOF = numListas então
EXISTEM_MAIS_NOMES := FALSE
...
fim FUNÇÃO
```

K-Way Merge

- Se for possível garantir que uma chave ocorre somente em uma lista/arquivo, o procedimento ficaria mais simples e eficiente
- Suponha o uso das listas LISTA e NOME
 - LISTA[i] contém os descritores dos arquivos de entrada
 - NOME[i] contém o nome (chave) associado a cada arquivo de entrada

K-Way Merge

Algoritmo modificado assumindo que não existem chaves duplicadas

```
#inicie o processo lendo um nome de cada lista
para i := 1 até K faça
  chame leia nome() para ler NOME[i] da LISTA[i]
fim para
#inicie a intercalação em K-vias
enquanto EXISTEM MAIS NOMES faça
  #encontre o nome de menor valor entre os nomes das K listas
  MENOR := 1
                                                Quanto maior for o valor de
  para i := 2 até K faça
    se NOME[i] < NOME[MENOR] então</pre>
                                                K, mais caro será encontrar
      MENOR := i
                                                         o menor
  fim para
  escreva NOME[MENOR] em SAIDA
  #leia o próximo nome da lista cujo nome foi para a saída
  chame o leia nome() para ler NOME[MENOR] da LISTA[MENOR]
fim enquanto
```