Hashing Extensível

Organização e Recuperação de Dados Profa. Valéria

UEM - CTC - DIN

Hashing extensivel

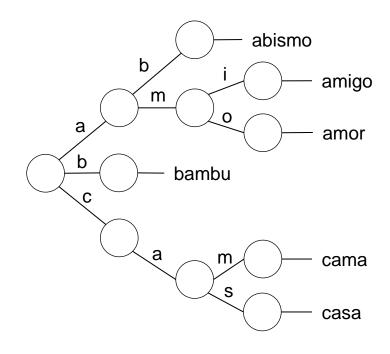
- Hashing extensível é uma técnica que permite que o espaço de endereços seja dinâmico
 - O <u>espaço de endereços</u> aumenta e diminui conforme as inserções/remoções acontecem
 - Não é mais necessário pré-definir a quantidade de endereços disponíveis, nem gerenciar colisões
 - O hashing manterá o seu desempenho mesmo que o arquivo cresça muitas vezes em tamanho

Hashing extensivel

- Combinação de duas estruturas:
 - Arquivo de buckets
 - Diretório com os endereços dos buckets
- O diretório é inspirado em uma estrutura de dados chamada trie
 - Uma trie é uma árvore de busca chamada de árvore digital, na qual o fator de divisão de cada nó é igual ao número de símbolos do alfabeto
 - As chaves são indexadas símbolo a símbolo (ou dígito a dígito)
 - Os n primeiros símbolos de uma chave definem o prefixo de tamanho
 n da chave

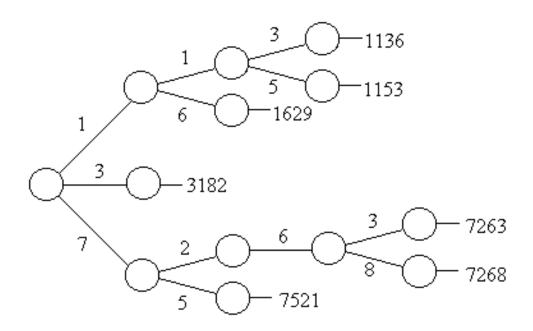
Trie

- Exemplo 1: Chaves alfabéticas (trie de 26 prefixos)
 - Supondo um alfabeto de a z,
 o fator de divisão é 26
 - Um prefixo da chave é utilizado como endereço
 - Cada caminho da raiz até as folhas compõe o menor prefixo necessário para identificar uma chave de forma única
 - Conforme novas chaves vão sendo inseridas, o espaço de endereços (caminhos possíveis) vai aumentando



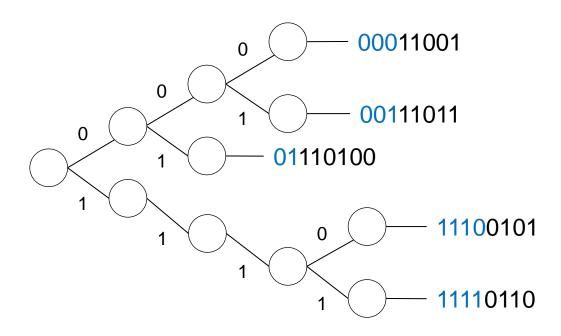
Trie

- **Exemplo 2**: Chaves numéricas (*trie de 10 prefixos*)
 - Alfabeto de 0 a 9, então o fator de divisão é 10, uma vez que existem
 10 símbolos possíveis



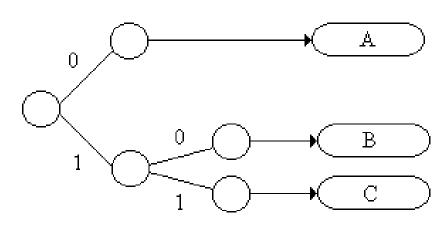
Trie

- Exemplo 3: Chaves binárias (trie de 2 prefixos trie binária)
 - Alfabeto 0 e 1, então o fator de divisão é 2



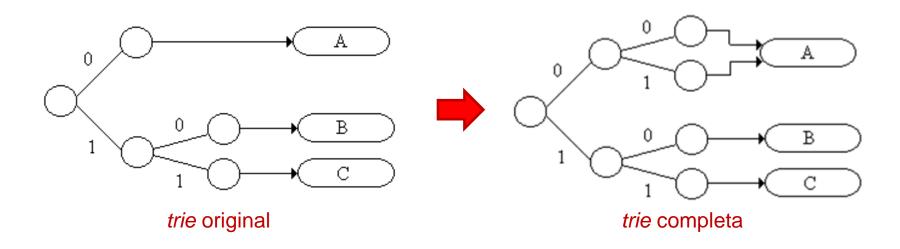
Transformando a *trie* em diretório

- O hashing extensível utiliza um diretório que é inspirado em uma trie binária
- A trie endereça buckets
 - O endereço gerado pela função hash é considerado bit-a-bit
- A figura ilustra uma trie endereçando os buckets A, B e C
 - O bucket A contém chaves cujos endereços começam com o bit 0
 - As chaves do bucket B produzem endereços que começam com os bits 10
 - As chaves no bucket C produzem endereços que começam com os bits 11



Transformando a *trie* em diretório

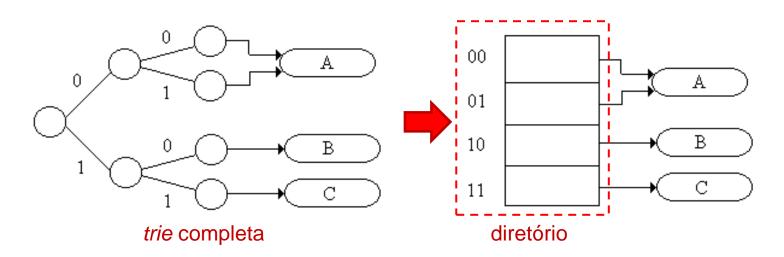
- O diretório do hashing extensível é a representação de uma trie binária completa
 - Uma trie completa possui todas as folhas no mesmo nível, i.e., todos os caminhos na trie têm o mesmo comprimento



Note que embora o bit **0** seja suficiente para endereçar o *bucket* A, a *trie* completa utiliza um segundo bit nesse caminho. Por isso, ambos endereços iniciados por **0** (**00** e **01**) apontam para o *bucket* A.

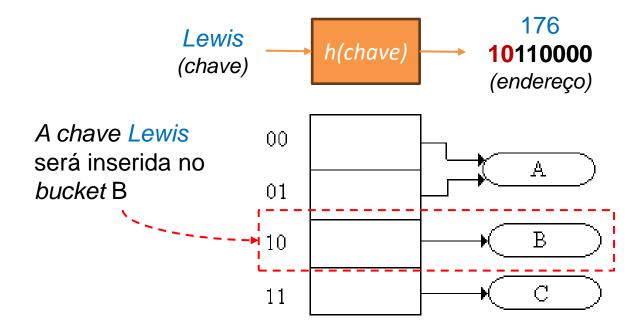
Transformando a *trie* em diretório

- - Cada entrada do diretório armazena <u>uma referência (RRN) para um</u> <u>bucket</u> associado



Acessando o diretório

- Dada uma chave e uma função hash, o endereço gerado pela função é usado para acessar uma entrada do diretório
 - Por ex., dada uma chave cujo endereço comece com os bits 10, a entrada 10 do diretório fornece a referência do bucket onde essa chave deve ser armazenada

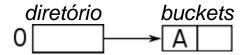


- Veremos o funcionamento do hashing extensível por meio de um exemplo:
 - Adaptado de Fagin, R.; Nievergelt, J.; Pippenger, N.; Strong, H. R. Extendible Hashing A Fast Access Method for Dynamic Files, ACM Transactions on Database Systems, v. 4, n. 3, p. 315–344, 1979.
- Suponha uma função h(k) que retorna um **número inteiro** como endereço



 Para simplificar o exemplo, vamos assumir que o tamanho do bucket é 1 (pode armazenar apenas uma chave), mas na prática os buckets serão maiores (blocos de registros)

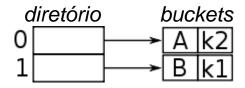
• Inicialmente, o hashing está vazio



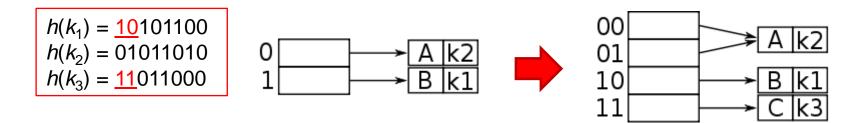
• Endereços retornados por h(k) para as chaves k_1 , e k_2 :

$$- h(k_1) = 172 = \underline{1}0101100$$
$$h(k_2) = 090 = \underline{0}1011010$$

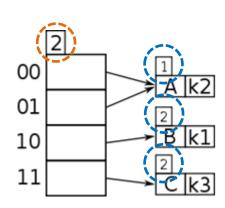
• k_1 e k_2 podem ser distinguidas pelo bit mais significativo e seriam inseridas nos *buckets* A e B:



- Quando for feito o *hashing* de k_3 , um bit não será mais suficiente para distinguir entre as três chaves
 - Ocorrerá <u>overflow</u> no <u>bucket</u> B (as chaves K_1 e k_3 colidem, pois o bucket está cheio)
 - Se usarmos os 2 bits mais significativos de cada chave, resolvemos o problema da colisão
 - Para isso, dobramos o tamanho do diretório e dividimos o bucket B



- Toda vez que o diretório aumenta, ele dobra de tamanho devido ao fato de estarmos usando números binários no endereçamento (2ⁿ)
- Chamamos de profundidade a quantidade de bits que está sendo utilizada nos endereços
- Inicialmente, o diretório tem profundidade 0 e tamanho 1 (2º = 1)
 - Se incluímos um bit nos endereços, o diretório passa a ter profundidade 1 e tamanho 2 ($2^1 = 2$)
 - E assim sucessivamente: $2^2 = 4$; $2^3 = 8$; $2^4 = 16$...
- Um overflow pode provocar o aumento do diretório, mas nem sempre!
- Para decidir se aumentamos o diretório, comparamos:
 - A quantidade de bits dos endereços do diretório, chamada de profundidade global
 - A quantidade de bits em comum dos endereços do bucket, chamada de profundidade local

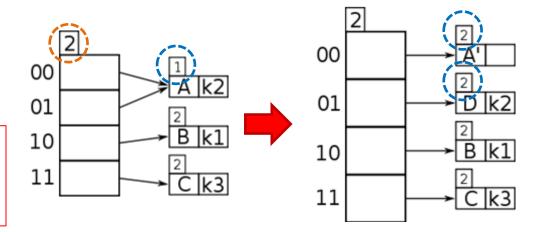


- O hashing da chave k_4 diz que ela deve ser inserida no bucket A
- O bucket A está cheio, então ocorre <u>overflow</u>
- Como a <u>profundidade local < profundidade global</u>, o *bucket* A é dividido e o diretório atual acomoda o novo *bucket*
- É criado um novo bucket (D) e a chave do bucket A é remapeada utilizando agora 2 bits do seu endereço base
 - As <u>profundidades</u> dos *buckets* A e D são incrementadas para 2

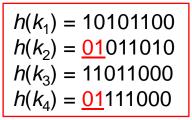
$$h(k_1) = 10101100$$

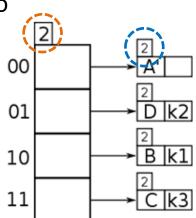
 $h(k_2) = 01011010$
 $h(k_3) = 11011000$
 $h(k_4) = 01111000$

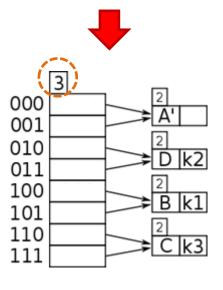
O problema é que a chave que estava em A é remapeada para D e com a inserção da chave k_4 o overflow continua no bucket D (k_2 e k_4 colidem)



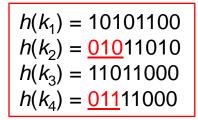
- O overflow continua no bucket D, então haverá nova divisão
- O diretório aumentará?
 - Agora sim, pois a <u>profundidade bucket</u>
 D = profundidade do diretório
 - Cada endereço de 2 bits será mapeado em dois endereços de 3 bits
 - Cada bucket passa a ter duas referências no diretório
 - A profundidade global passa a ser igual a 3

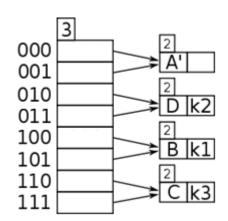


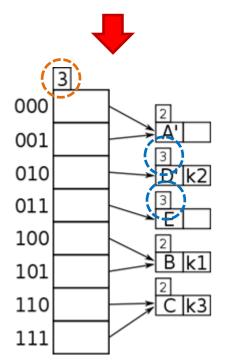




- O diretório aumentou e a profundidade global agora é 3
 - O bucket D (profundidade local = 2) é dividido, gerando o bucket E, ambos com profundidade local = 3
 - A chave do *bucket* D é remapeada usando 3 bits do seu endereço e fica em D mesmo $(h(k_2) = 01011010)$
 - A chave k_4 também é remapeada usando 3 bits do seu endereço ($h(k_4) = 0111000$) e vai para o bucket E







- Situação final:
 - Endereços

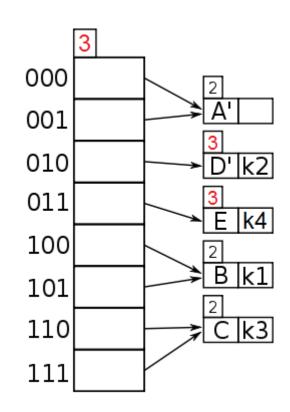
$$-h(k_1) = 10101100$$

$$-h(k_2) = 01011010$$

$$-h(k_3) = 11011000$$

$$-h(k_4) = 01111000$$

Profundidade global = 3

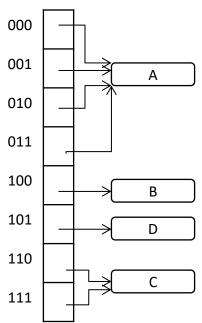


Resumindo

- Quando o hashing está vazio, a profundidade global é zero, assim como a profundidade local do bucket ligado ao diretório
- Sempre que o diretório dobrar o tamanho, a profundidade global é incrementada em 1
- No momento da divisão de um bucket (overflow):
 - Se a profundidade do bucket a ser dividido for menor que profundidade global, um novo bucket é criado e mapeado no diretório existente
 - Se a profundidade do bucket a ser dividido for <u>igual</u> a profundidade global, o diretório deverá ser aumentado antes da divisão, causando incremento na profundidade global
 - Sempre que um bucket é dividido, sua profundidade é incrementada em 1 e o novo bucket passa a ter a mesma profundidade daquele que o originou

Hashing extensivel

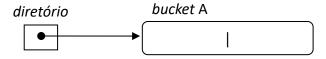
- Na figura, temos um diretório "desbalanceado"
 - Ele tem o dobro do tamanho necessário
- O bom funcionamento do hashing extensível continua dependendo da função hash
 - Se a função hash produz uma distribuição ruim, a tendência é que o diretório cresça além do necessário



- A função hash para um hashing extensível pode ser a mesma usada no hashing estático, mas a modulação pelo tamanho do espaço de endereços não é mais necessária
 - Em contrapartida, precisamos de uma função para analisar o endereço hash gerado bit a bit

Exercício 1

 Suponha um hashing extensível em que cada bucket pode armazenar dois registros. Inicialmente o sistema está vazio (as profundidades global e local são iguais a zero)



 Mostre como ficam o diretório e os buckets após a inserção das chaves k1, k2, k3, k4, k5 e k6, nesta ordem, sabendo que os respectivos endereços bases são: 1111, 0000, 1100, 1010, 0101, 1110. Indique as profundidades global e locais nas representações geradas

$$h(K1) = 1111$$

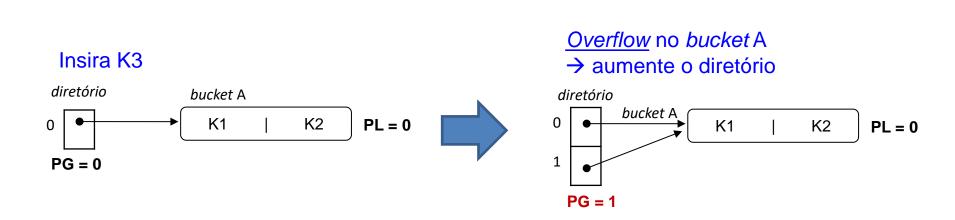
 $h(K2) = 0000$

Insira K1 e K2



$$h(K1) = 1111$$

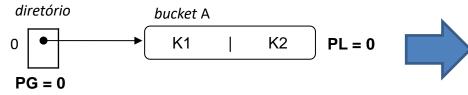
 $h(K2) = 0000$
 $h(K3) = 1100$



$$h(K1) = 1111$$

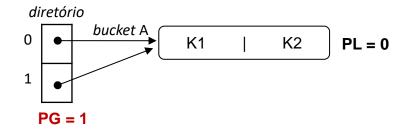
 $h(K2) = 0000$
 $h(K3) = 1100$

Insira K3





Overflow no bucket A → aumente o diretório

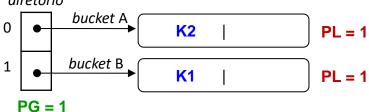


Divida o *bucket* A e remapeie as chaves usando um bit

$$K1 = 1111$$

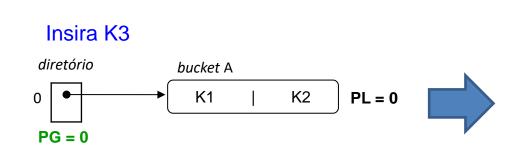
$$K2 = 0000$$

diretório



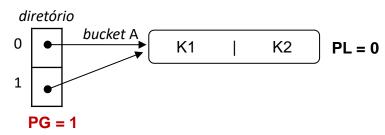
$$h(K1) = 1111$$

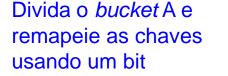
 $h(K2) = 0000$
 $h(K3) = 1100$



Overflow no bucket A

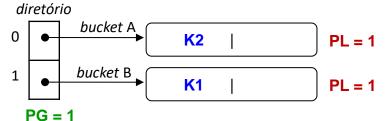
→ aumente o diretório





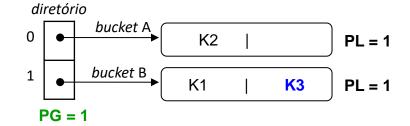
$$K1 = 1111$$

 $K2 = 0000$



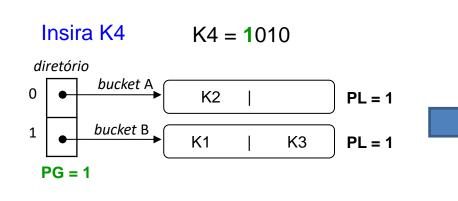


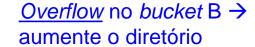
Insira K3 K3 = 1100

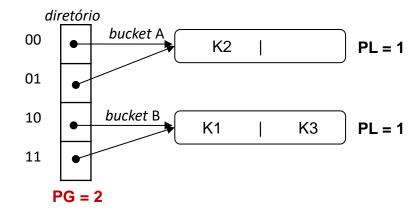


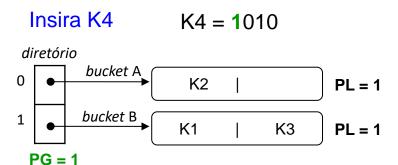
h(K1) = 1111 h(K2) = 0000 h(K3) = 1100h(K4) = 1010

Inserção







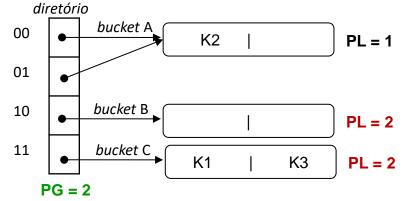




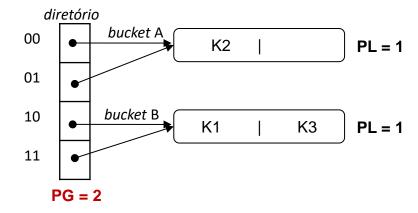
Divida o *bucket* B e remapeie as chaves usando dois bits

$$K1 = 1111$$

 $K3 = 1100$



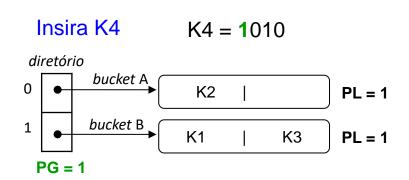
Overflow no bucket B → aumente o diretório





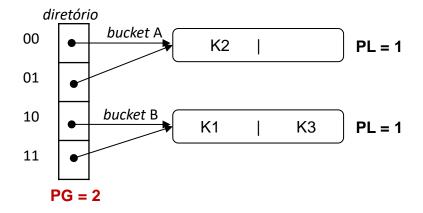
$$h(K1) = 1111$$

 $h(K2) = 0000$
 $h(K3) = 1100$
 $h(K4) = 1010$





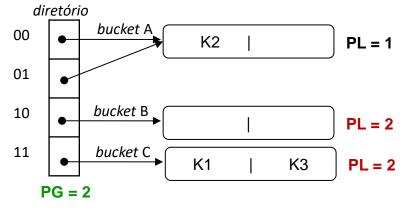
Overflow no bucket B → aumente o diretório



Divida o *bucket* B e remapeie as chaves usando dois bits

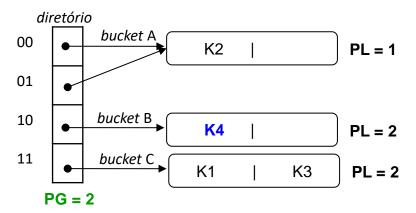
$$K1 = 1111$$

 $K3 = 1100$

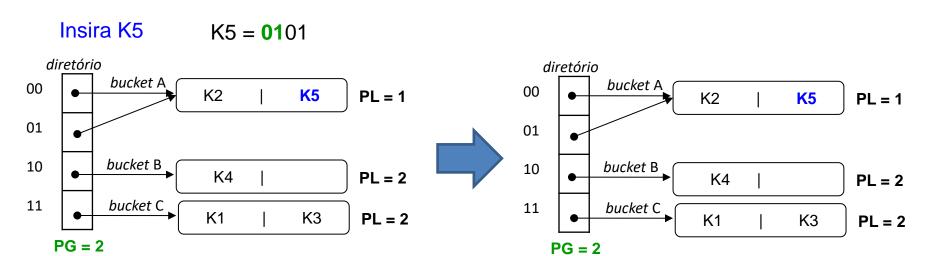




Insira K4 K4 = 1010

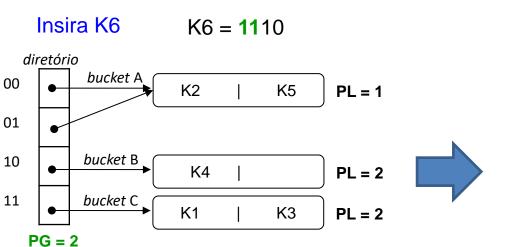


$$h(K1) = 1111$$
 $h(K4) = 1010$
 $h(K2) = 0000$ $h(K5) = 0101$
 $h(K3) = 1100$

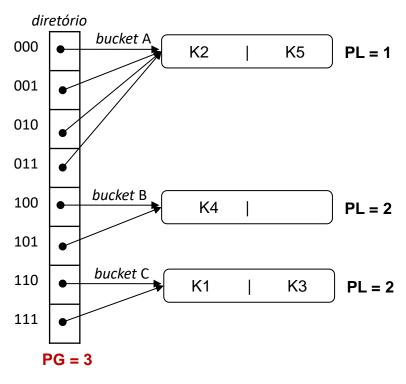


h(K1) = 1111 h(K4) = 1010 h(K2) = 0000 h(K5) = 0101h(K3) = 1100 h(K6) = 1110

Inserção



<u>Overflow</u> no bucket C → aumente o diretório

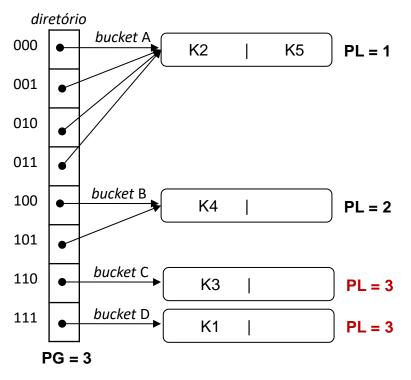


$$h(K1) = 1111$$
 $h(K4) = 1010$
 $h(K2) = 0000$ $h(K5) = 0101$
 $h(K3) = 1100$ $h(K6) = 1110$

Divida o *bucket* C e remapeie as chaves usando três bits

$$K1 = 1111$$

 $K3 = 1100$



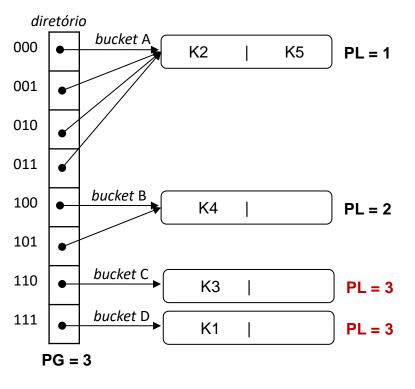
h(K1) = 1111 h(K4) = 1010 h(K2) = 0000 h(K5) = 0101h(K3) = 1100 h(K6) = 1110

Inserção

Divida o *bucket* C e remapeie as chaves usando três bits

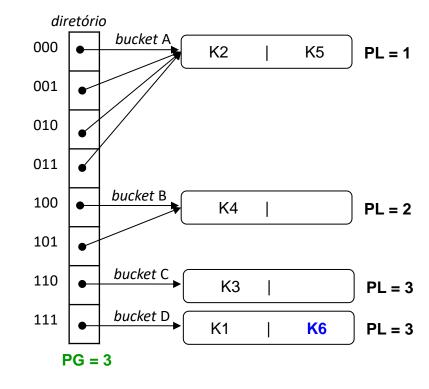
$$K1 = 1111$$

 $K3 = 1100$

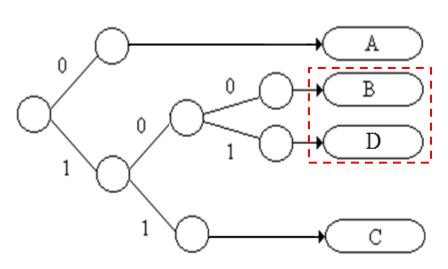


Insira K6

K6 = 1110

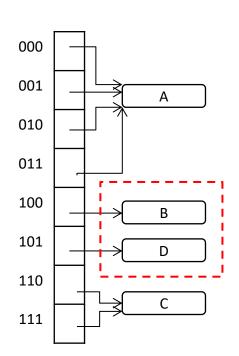


- Para ser uma estrutura dinâmica, não basta que o hashing extensível seja capaz de aumentar de tamanho, ele também deve ser capaz de diminuir
- Relembrando a concatenação nas árvores-B
 - Apenas páginas <u>irmãs imediatas</u> podiam ser concatenadas
 - A concatenação sempre se iniciava com duas páginas <u>folhas</u>
- No hashing extensivel
 - Dois buckets podem ser concatenados apenas quando são filhos imediatos de um mesmo nó na trie
 - Além disso, eles devem estar
 no nível mais baixo da trie

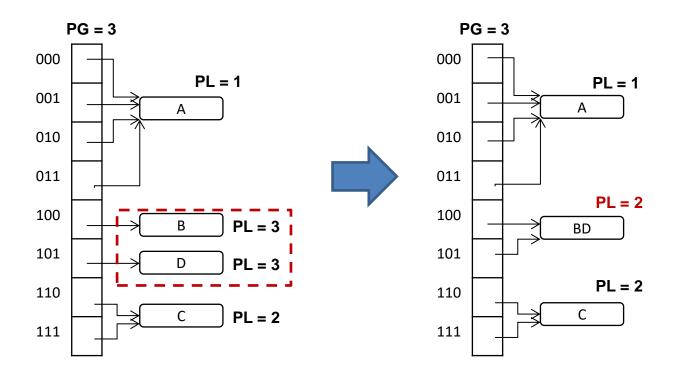


- Como saber se o bucket está no nível mais baixo da trie?
 - Comparando a profundidade local com a global
 - Se elas forem iguais, o bucket está no último nível
- Dado um determinado bucket, como encontrar o seu "par"?
 - Todo bucket tem um único par
 - O par pode ser encontrado invertendo-se o bit menos significativo do endereço do bucket
- Chamaremos dois buckets que podem ser concatenados de "amigos" (buddy buckets)

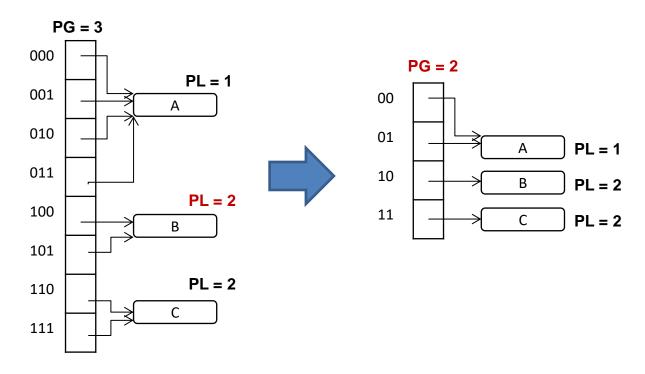
B e D são buckets amigos



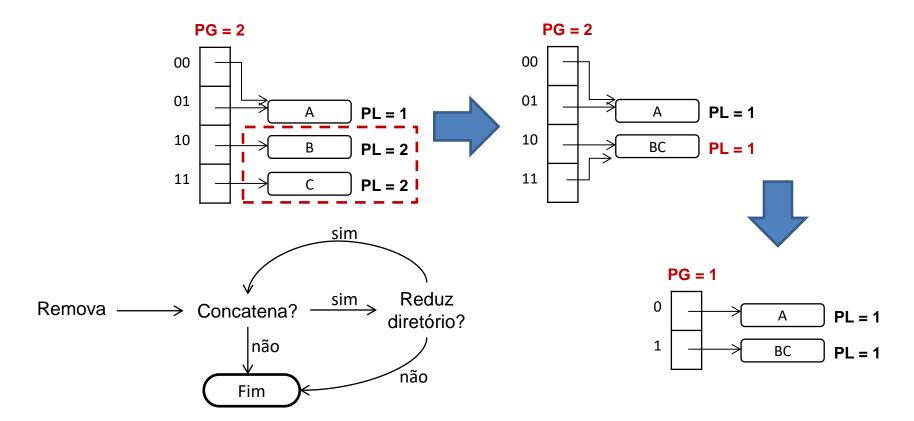
 Quando os buckets amigos são concatenados, a profundidade do bucket resultante diminui em 1



- Após uma concatenação, é possível que o <u>diretório</u> possa reduzir o seu tamanho
 - Se todos os buckets possuírem pelo menos duas referências para eles,
 o diretório pode ser reduzido à metade do tamanho

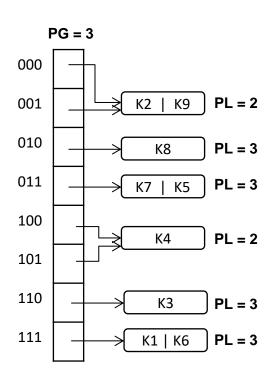


 Quando o diretório reduz de tamanho, é possível que um novo bucket amigo surja e uma nova concatenação possa ser realizada



Exercício 2

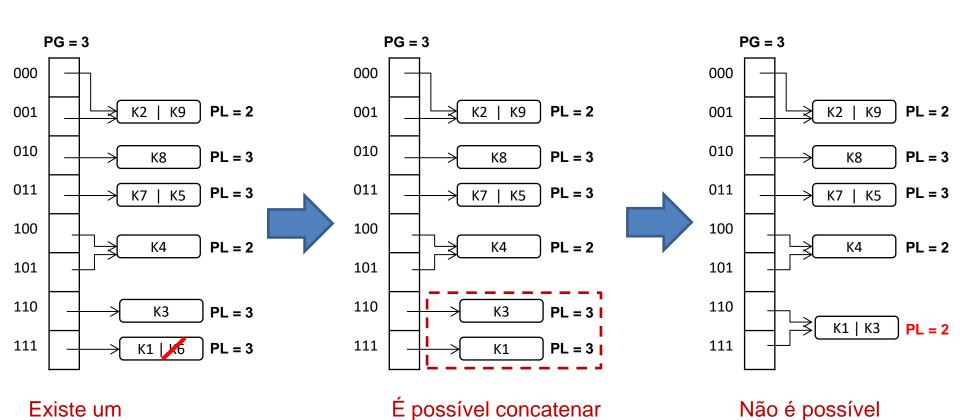
 Considere o hashing extensível mostrado na figura e simule as remoções das seguintes chaves, nesta ordem:



K6, K9, K7, K3, K1, K5, K8

K6, K9, K7, K3, K1, K5, K8

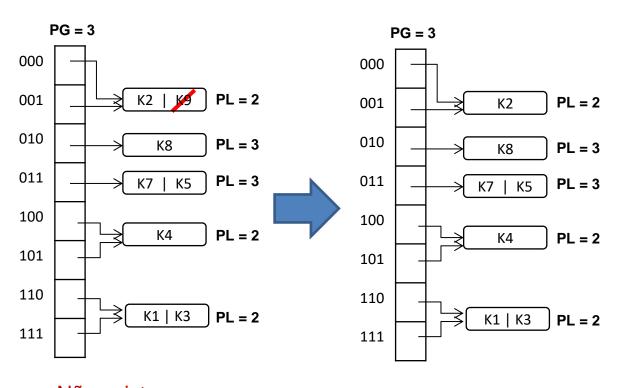
diminuir o diretório



com o amigo

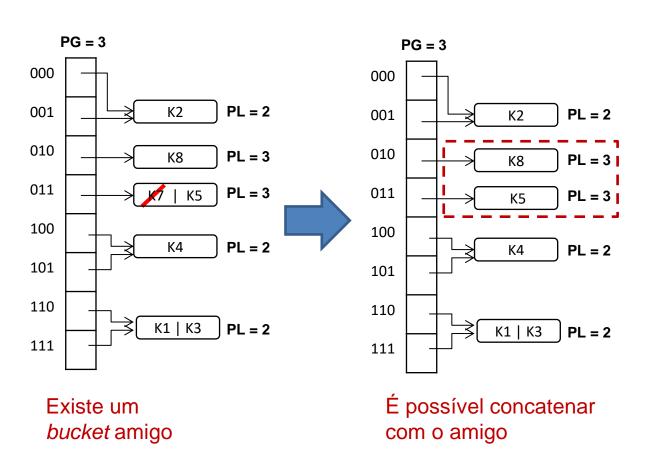
bucket amigo

K6, K9, K7, K3, K1, K5, K8



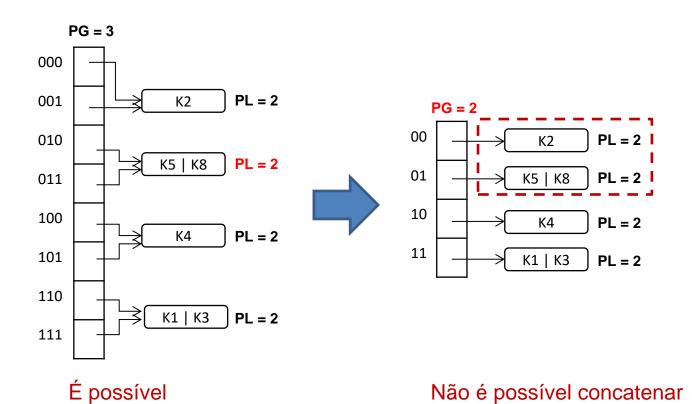
Não existe um bucket amigo

K6, K9, K7, K3, K1, K5, K8



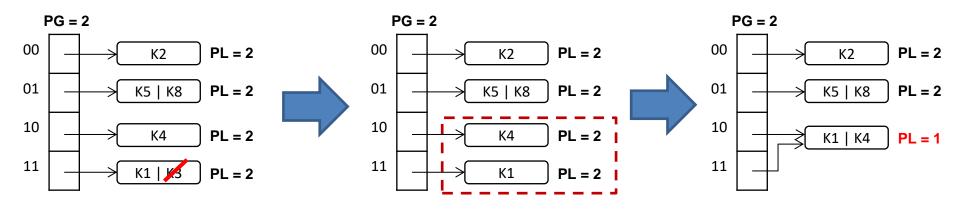
K6, K9, K7, K3, K1, K5, K8

com o novo amigo



diminuir o diretório

K6, K9, K7, K3, K1, K5, K8

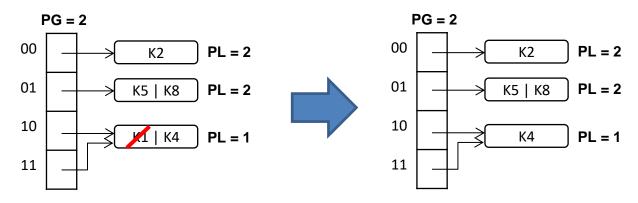


Existe um bucket amigo

É possível concatenar com o amigo

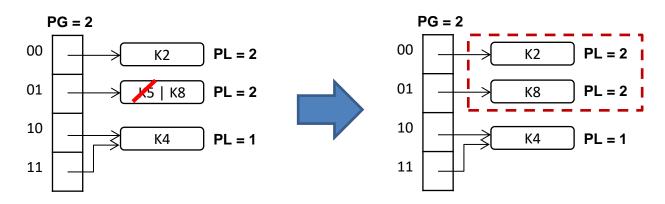
Não é possível diminuir o diretório

K6, K9, K7, K3, K1, K5, K8



Não existe um bucket amigo

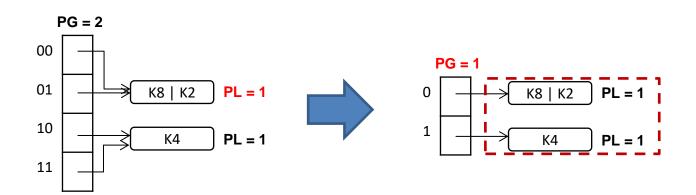
K6, K9, K7, K3, K1, <u>K5</u>, K8



Existe um bucket amigo

É possível concatenar com o amigo

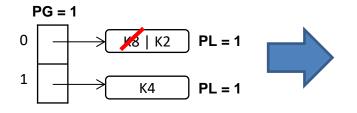
K6, K9, K7, K3, K1, K5, K8

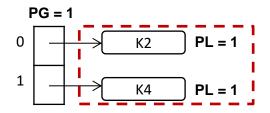


É possível diminuir o diretório

Não é possível concatenar com o novo amigo

K6, K9, K7, K3, K1, K5, <u>K8</u>





Existe um bucket amigo

É possível concatenar com o amigo

K6, K9, K7, K3, K1, K5, <u>K8</u>

